

Proyecto integrador

Clasificación supervisada de eventos sísmicos peligrosos en minería subterránea: comparación de árbol de decisión, Naive Bayes, k-NN y regresión logística

Martinez Mauricio Leonel

DNI: 45.549.925

2026

1. Introducción

La minería subterránea puede estar expuesta a eventos sísmicos de alta energía que representan un riesgo para la seguridad de los trabajadores, la infraestructura y la continuidad de las operaciones. Estos eventos pueden producir desprendimientos, daños materiales, interrupciones de la actividad y condiciones de trabajo que requieren una respuesta rápida. En este contexto, la disponibilidad de registros históricos de actividad sísmica y sismoacústica permite estudiar si los patrones observados durante un turno contienen información útil para anticipar el nivel de peligrosidad del turno siguiente.

Este proyecto integrador presenta un estudio de clasificación supervisada aplicado al conjunto de datos *Seismic-Bumps*. El problema se formula como una clasificación binaria: cada instancia se asigna a una clase no peligrosa o a una clase peligrosa. El trabajo compara cuatro algoritmos: árbol de decisión, Naive Bayes, k-NN y regresión logística, tanto en sus configuraciones base como en variantes entrenadas con SMOTE. La evaluación no se limita a la exactitud global, porque la clase peligrosa es minoritaria y, por lo tanto, un clasificador que favorezca sistemáticamente la clase mayoritaria puede presentar una exactitud elevada sin detectar una proporción suficiente de los eventos relevantes.

El objetivo es establecer una comparación empírica reproducible, documentar el efecto del desbalance y determinar qué configuración ofrece el mejor compromiso entre rendimiento global y detección de la clase peligrosa. En particular, se analiza la relación entre exactitud, AUC (optimistic), precisión, recall y F1. Esta lectura conjunta evita conclusiones basadas en una única métrica y permite formular una conclusión final dentro del alcance del conjunto de datos y del procedimiento utilizado.

2. Problema y pregunta de investigación

La tarea se formula como un problema de clasificación binaria sobre registros de actividad sísmica. La etiqueta `class` toma el valor 0 para un registro no peligroso y el valor 1 para un registro peligroso. El interés práctico se encuentra en la clase 1, ya que sus

errores de omisión pueden tener un costo mayor que los errores asociados a la emisión de una alerta innecesaria.

El problema central consiste en determinar si los 18 atributos predictivos disponibles permiten distinguir de manera útil ambas clases y qué comportamiento presentan el árbol de decisión, Naive Bayes, k-NN y la regresión logística bajo un procedimiento de evaluación común. La dificultad principal surge de la distribución desigual de la variable objetivo: la clase 0 reúne la gran mayoría de los registros, mientras que la clase 1 representa una proporción reducida. En consecuencia, la exactitud debe interpretarse junto con la matriz de confusión y con métricas específicas de la clase positiva.

La pregunta de investigación que orienta el trabajo es:

¿Qué diferencias presentan un árbol de decisión, Naive Bayes, k-NN y regresión logística en términos de rendimiento global y detección de la clase peligrosa en el conjunto Seismic-Bumps, bajo un procedimiento de evaluación común?

La comparación final incluye el árbol de decisión base, Naive Bayes base, k-NN con $k = 5$, regresión logística y las variantes con SMOTE verificadas en AI Studio.

3. Objetivos

El objetivo general es analizar comparativamente el comportamiento de un árbol de decisión, Naive Bayes, k-NN y regresión logística para clasificar la ocurrencia de eventos sísmicos peligrosos en el conjunto Seismic-Bumps.

Los objetivos específicos son:

- describir el tamaño, la estructura y la distribución de clases del conjunto de datos;
- establecer un procedimiento reproducible de evaluación mediante validación cruzada estratificada;
- configurar y evaluar los cuatro algoritmos planificados mediante un procedimiento común;
- documentar los resultados obtenidos en Altair AI Studio para los cuatro modelos base y sus variantes con SMOTE;
- analizar las matrices de confusión con filas verdaderas y columnas predichas;
- comparar exactitud, AUC, precisión, recall y F1 de la clase peligrosa sin reducir la evaluación a una sola métrica;
- interpretar las diferencias entre rendimiento global y capacidad de detección de la clase minoritaria; y
- construir una comparación conjunta de los cuatro algoritmos sin reducir la selección a una única métrica.

4. Descripción del conjunto de datos

Se utilizó el conjunto *Seismic-Bumps*, disponible en el repositorio público UCI Machine Learning Repository. El archivo local utilizado en el flujo de trabajo es `seismic-bumps.arff`. El conjunto contiene 2584 instancias y 19 atributos en total: 18 atributos predictivos y una variable objetivo denominada `class`. En la inspección realizada no se detectaron valores faltantes.

Cuadro 1: Características generales del conjunto de datos.

Característica	Descripción
Nombre	Seismic-Bumps
Instancias	2584
Atributos totales	19
Atributos predictivos	18
Variable objetivo	<code>class</code>
Formato	ARFF
Valores faltantes	No detectados

La distribución de la variable objetivo muestra un desbalance marcado. La clase 0 contiene 2414 instancias, equivalentes al 93,42% del conjunto, mientras que la clase 1 contiene 170 instancias, equivalentes al 6,58%. Esta diferencia debe ser tomada en cuenta en la interpretación: un modelo puede acertar una gran cantidad de registros de la clase 0 y, al mismo tiempo, omitir la mayoría de los casos de la clase 1.

4.1. Tratamiento del desbalance

La distribución observada equivale aproximadamente a una relación de 14,2 registros de la clase 0 por cada registro de la clase 1. En este contexto, la exactitud puede resultar engañosa: un clasificador que predijera casi siempre la clase mayoritaria podría alcanzar una proporción elevada de aciertos y, sin embargo, detectar muy pocos eventos peligrosos. Por ello, la evaluación deberá considerar especialmente la capacidad de identificar la clase 1, junto con el costo asociado a los falsos positivos y falsos negativos.

Como extensión complementaria se evalúa el uso de SMOTE (Synthetic Minority Over-sampling Technique), propuesto por Chawla et al. (2002). SMOTE genera ejemplos sintéticos de la clase minoritaria a partir de la combinación de observaciones existentes y sus vecinos cercanos; por lo tanto, los nuevos registros no son observaciones reales del conjunto original, sino construcciones artificiales destinadas a mejorar la representación de la clase 1 durante el entrenamiento. A diferencia del submuestreo, que reduce la cantidad de observaciones de la clase mayoritaria y puede descartar información, SMOTE conserva esas observaciones. También se diferencia del oversampling aleatorio, que replica registros minoritarios existentes, mientras que SMOTE busca generar nuevas muestras sintéticas. En este proyecto se verificaron cuatro variantes con SMOTE: árbol de decisión, k-NN con $k = 5$, regresión logística y Naive Bayes. Esta extensión complementa, pero no reemplaza, la comparación de los cuatro modelos base.

En las ejecuciones complementarias verificadas, la aplicación de SMOTE se limita exclusivamente al subproceso de entrenamiento de la validación cruzada. De este modo, los ejemplos sintéticos se generan únicamente a partir de los datos utilizados para entrenar,

evitando que información del conjunto de prueba influya en el ajuste del modelo. El conjunto de prueba conserva la distribución original del conjunto, sin aplicar SMOTE, para que la evaluación represente la frecuencia de clases observada en los datos. La comparación principal con los cuatro algoritmos base se mantiene separada; cada variante con SMOTE se analiza frente a la línea de base del mismo learner.

En el árbol de decisión, SMOTE se aplica antes del learner y no se incorpora el operador *Normalize*, porque el árbol no depende de distancias entre atributos. En k-NN se conserva *Normalize* antes de SMOTE y se mantiene el agrupamiento del preprocesamiento con el clasificador. En regresión logística, SMOTE precede a *Generalized Linear Model*. En Naive Bayes, SMOTE precede al entrenamiento del clasificador dentro del flujo mostrado en la Figura 13. En los cuatro casos, *Testing* recibe datos con la distribución original y el modelo se evalúa mediante *Apply Model* y *Performance*.

El uso de SMOTE también introduce riesgos metodológicos que deben ser examinados. Los ejemplos sintéticos pueden amplificar ruido, generar observaciones en regiones de solapamiento entre clases o favorecer un aumento de falsos positivos. Por esta razón, SMOTE se incorpora como una alternativa experimental y no como una mejora asumida de antemano; sus resultados deben interpretarse conjuntamente con la matriz de confusión, el recall, la precisión, el F1 y el AUC.

Cuadro 2: Distribución de la variable objetivo.

Clase	Cantidad	Proporción
No peligrosa (0)	2414	93,42 %
Peligrosa (1)	170	6,58 %
Total	2584	100,00 %




Figura 1: Distribución de las clases del conjunto Seismic-Bumps.

Los atributos describen condiciones y mediciones asociadas con la actividad registrada durante los turnos. La variable objetivo resume la ocurrencia de un evento clasificado como peligroso. En este proyecto, el conjunto se utiliza como fuente de observaciones históricas para comparar algoritmos; los resultados no se interpretan como una validación operativa en tiempo real.

5. Metodología y plan de análisis

El plan de análisis se organiza en cuatro etapas. Primero, se verifica la estructura del archivo ARFF, el número de instancias, la cantidad de atributos, la ausencia de valores faltantes y la distribución de la clase objetivo. Segundo, se configuran el árbol de decisión, Naive Bayes, k-NN y la regresión logística en Altair AI Studio con los mismos datos y el mismo esquema de evaluación. Tercero, se examinan las matrices de confusión y las métricas globales y de clase de cada algoritmo. Finalmente, se realiza una interpretación conjunta que distingue la exactitud de la capacidad efectiva para detectar la clase peligrosa.

Todos los resultados empíricos presentados fueron obtenidos mediante Altair AI Studio utilizando validación cruzada estratificada de 10 particiones. La estratificación busca conservar, dentro de cada partición, una representación comparable de las dos clases. De esta forma, las métricas reportadas reflejan el comportamiento promedio del procedimiento sobre diferentes particiones y no el desempeño en una única división arbitraria del conjunto.

Las matrices se expresan con filas verdaderas y columnas predichas. En esta convención, para la clase 1 se definen los verdaderos positivos como los registros peligrosos correctamente identificados, los falsos negativos como los registros peligrosos clasificados como no peligrosos y los falsos positivos como los registros no peligrosos clasificados como peligrosos. Las métricas agregadas se calculan a partir de la matriz total:

$$\text{precision} = \frac{TP}{TP + FP}, \quad \text{recall} = \frac{TP}{TP + FN},$$

$$F1 = \frac{2 \cdot \text{precision} \cdot \text{recall}}{\text{precision} + \text{recall}}.$$

Además de los valores agregados, se consignan cuando están disponibles los valores del encabezado de AI Studio y su variabilidad entre particiones. Esta distinción es importante: los promedios informados por la herramienta y los cocientes calculados a partir de la matriz acumulada no necesariamente coinciden exactamente, porque se obtienen mediante operaciones diferentes.




Figura 2: Esquema del proceso de trabajo utilizado para obtener los resultados mediante Altair AI Studio.




Figura 3: Esquema de la validación cruzada estratificada utilizada en la evaluación.

6. Implementación y configuración de k-NN

El algoritmo k-NN se incorporó al flujo de evaluación como el tercer modelo analizado. Debido a que este método clasifica una instancia a partir de la proximidad de sus vecinos, la escala de las variables numéricas afecta directamente el cálculo de las distancias. En el conjunto *Seismic-Bumps*, las variables numéricas no se encuentran necesariamente en el mismo rango; por este motivo, una variable con valores de mayor magnitud podría dominar la medida de distancia aunque no fuera la más informativa para la clasificación.

Para reducir este efecto se utilizó el operador *Normalize* antes de k-NN. La normalización transforma las variables numéricas a una escala comparable y evita que las diferencias de magnitud determinen por sí solas qué observaciones se consideran cercanas. La transformación se ajusta dentro del subproceso de entrenamiento de cada partición de la validación cruzada, de manera que los parámetros calculados a partir del conjunto de entrenamiento no incorporen información del conjunto de prueba.

La salida *pre* de *Normalize* se conectó a *Group Models* junto con el modelo generado por k-NN. Este operador agrupa el modelo de preprocesamiento y el clasificador en un único modelo compuesto. Así, al aplicar el modelo a datos no vistos, primero se reproduce la misma transformación de normalización y luego se ejecuta la clasificación k-NN. Esta conexión evita que el modelo se entrene con datos normalizados y se aplique a datos de prueba en una escala diferente, y mantiene el preprocesamiento dentro del ciclo de validación cruzada. La Figura 4 muestra el flujo implementado.




Figura 4: Flujo de k-NN con normalización y agrupación del modelo de preprocesamiento mediante *Group Models*.

El parámetro k se evaluó con los valores impares 3, 5, 7 y 9. En todos los casos se mantuvieron constantes el conjunto de datos, la normalización, la validación cruzada estratificada de 10 particiones y el resto del flujo. Los resultados se compararon priorizando la detección de la clase 1, sin dejar de considerar la precisión, el F1, la exactitud y el AUC informado por AI Studio.

7. Implementación y configuración de la regresión logística

La regresión logística se implementó mediante el operador *Generalized Linear Model* con familia binomial. Esta formulación utiliza el enlace logit para relacionar linealmente los atributos con el logaritmo de las probabilidades relativas de pertenecer a la clase 1. En consecuencia, el modelo estima la probabilidad de que un registro corresponda a la clase peligrosa y la transforma en una decisión de clase mediante el umbral utilizado por AI Studio.

El modelo se entrenó dentro del subproceso de entrenamiento de una validación cruzada estratificada de 10 particiones. En cada iteración, el *Generalized Linear Model* se ajustó únicamente con nueve particiones y su salida se aplicó a la partición de prueba mediante *Apply Model*. Luego, el operador *Performance* calculó la matriz de confusión y las métricas correspondientes. La Figura 5 muestra este flujo. SMOTE no forma parte de esta ejecución base y se documenta junto con las variantes verificadas en la sección del experimento complementario.

8. Cierre del proyecto integrador

El proyecto integrador queda cerrado con la carga e inspección del conjunto de datos, la descripción de la variable objetivo, la configuración del flujo de evaluación y la obtención de resultados para los cuatro algoritmos base y sus variantes con SMOTE. La evidencia se organiza mediante matrices de confusión y métricas globales y específicas de la clase peligrosa.




Figura 5: Flujo de entrenamiento y prueba de la regresión logística mediante *Generalized Linear Model* dentro de la validación cruzada.

La conclusión metodológica es explícita: SMOTE se aplica solamente durante el entrenamiento y la evaluación se realiza sobre el conjunto de testing original. Esto evita la contaminación entre entrenamiento y prueba y permite comparar el efecto del sobremuestreo con la línea de base correspondiente.

El alcance de la conclusión es el conjunto *Seismic-Bumps* y el procedimiento de validación cruzada implementado en Altair AI Studio. El trabajo no afirma que los modelos constituyan un sistema operativo de alerta ni una validación temporal; esa delimitación es una condición de validez de los resultados, no un pendiente del proyecto.

9. Primer resultado empírico (Decision Tree base)

El árbol de decisión base obtuvo una exactitud de $92,84\% \pm 0,27\%$ y un AUC (optimistic) de $0,860 \pm 0,041$, según los resultados de AI Studio. La exactitud es elevada en relación con la proporción de la clase mayoritaria. La denominación de AUC reproduce el criterio configurado en el operador *Performance* del proceso disponible y se mantiene para evitar presentarlo como AUC estándar.

La matriz total, con filas verdaderas y columnas predichas, fue:

Cuadro 3: Matriz de confusión del Decision Tree base.

	Predicha 0	Predicha 1
Verdadera 0	2394	20
Verdadera 1	165	5

La matriz permite distinguir el origen de la exactitud. El modelo clasifica correctamente 2394 registros de la clase 0, pero solo identifica 5 de los 170 registros de la clase 1. En consecuencia, produce 20 falsos positivos y 165 falsos negativos. La proporción de falsos negativos entre los casos peligrosos es, por tanto, muy alta.

A partir de la matriz total, la precisión de la clase 1 es $20,00\%$, el recall agregado es $2,94\%$ y el F1 agregado es $5,13\%$. El encabezado de AI Studio informa para el recall un

valor de $3,05\% \pm 4,36\%$. La diferencia entre $3,05\%$ y $2,94\%$ se explica por la diferencia entre el promedio de los resultados por partición y el cálculo realizado sobre los conteos acumulados.




Figura 6: Errores de clasificación de la clase peligrosa para el Decision Tree base, obtenidos mediante AI Studio.




Figura 7: Matriz de confusión del Decision Tree base, con filas verdaderas y columnas predichas.

El resultado muestra que una exactitud cercana al 93% puede coexistir con una cobertura muy baja de la clase peligrosa. En este caso, la métrica global resume principalmente el comportamiento sobre la clase 0, que constituye el $93,42\%$ de las instancias. Por eso, el análisis del árbol base debe centrarse menos en su exactitud aislada y más en el costo potencial de omitir casos de la clase 1.

10. Segundo resultado empírico: Naive Bayes base

Naive Bayes base obtuvo una exactitud de $84,75\% \pm 4,31\%$ y un AUC (optimistic) de $0,761 \pm 0,043$, según AI Studio. Su exactitud es inferior a la del árbol de decisión base y también presenta una variabilidad mayor en la exactitud entre particiones. En cambio, la matriz muestra una detección considerablemente mayor de los casos de la clase 1.

La matriz total fue:

Cuadro 4: Matriz de confusión de Naive Bayes base.

	Predicha 0	Predicha 1
Verdadera 0	2120	294
Verdadera 1	100	70

Naive Bayes identifica correctamente 70 de los 170 registros peligrosos. Para lograrlo, clasifica como positivos 364 registros en total: 70 son verdaderos positivos y 294 son falsos positivos. El modelo también produce 100 falsos negativos, una cantidad inferior a la del árbol base, aunque no logra detectar todos los casos peligrosos.

Las métricas agregadas calculadas a partir de la matriz son precisión $19,23\%$, recall $41,18\%$ y F1 $26,22\%$. El encabezado de AI Studio informa una precisión de $20,24\% \pm 4,89\%$, un recall de $41,20\% \pm 6,84\%$ y un F1 de $26,80\% \pm 5,24\%$. Al igual que en el caso anterior, los valores agregados y los promedios del encabezado deben leerse como resúmenes complementarios del mismo procedimiento de validación.




Figura 8: Errores de clasificación de la clase peligrosa para Naive Bayes base, obtenidos mediante AI Studio.




Figura 9: Matriz de confusión de Naive Bayes base, con filas verdaderas y columnas predichas.

El comportamiento de Naive Bayes evidencia el intercambio entre detección y falsas alarmas. Frente al árbol base, aumenta sustancialmente la cantidad de casos peligrosos detectados, pero también asigna la clase positiva a muchos registros que pertenecen a la clase 0. Por lo tanto, su menor exactitud no implica necesariamente un resultado menos útil si el objetivo prioritario es reducir la omisión de eventos peligrosos.

11. Tercer resultado empírico: k-NN

La evaluación de k-NN se realizó después de incorporar la normalización y de agrupar el preprocesamiento con el clasificador. La Tabla 5 resume los resultados obtenidos para los cuatro valores candidatos de k . El criterio denominado “AUC (optimistic)” corresponde exactamente al indicador mostrado por AI Studio; no se lo presenta como AUC estándar ni se lo interpreta como equivalente a este último.

Cuadro 5: Selección del parámetro k para k-NN.

k	Accuracy	AUC (optimistic)	Precision clase 1	Recall clase 1	F1 clase 1
3	92,38 %	0,892	26,32 %	8,82 %	13,22 %
5	93,07 %	0,851	39,02 %	9,41 %	15,17 %
7	93,23 %	0,825	40,00 %	5,88 %	10,26 %
9	93,23 %	0,804	36,84 %	4,12 %	7,41 %

Entre los valores evaluados, se seleccionó $k = 5$ como configuración final de k-NN. Este valor maximiza simultáneamente el recall y el F1 de la clase 1: identifica 16 de los 170 registros peligrosos y obtiene un recall de 9,41 %. El valor $k = 3$ alcanza el AUC (optimistic) más alto, 0,892, pero presenta una precisión de clase 1 de 26,32 % y un F1 de

13,22 %, inferiores a los de $k = 5$. Por su parte, $k = 7$ y $k = 9$ conservan una exactitud similar o mayor, pero reducen la detección de la clase peligrosa. La selección de $k = 5$ es, por lo tanto, una elección relativa entre los candidatos probados y no implica que el recall absoluto sea suficiente para un sistema operativo de alertas.

La matriz de confusión de la configuración seleccionada se presenta en la Tabla 6. La convención es la misma que en los modelos anteriores: las filas corresponden a la clase verdadera y las columnas a la clase predicha.

Cuadro 6: Matriz de confusión de k-NN con $k = 5$.

	Predicha 0	Predicha 1
Verdadera 0	2389	25
Verdadera 1	154	16

La matriz muestra que el modelo seleccionado produce 25 falsos positivos y 154 falsos negativos. Por consiguiente, aunque k-NN mejora el recall y el F1 respecto de los otros valores de k probados, todavía omite la mayoría de los registros de la clase peligrosa.

12. Cuarto resultado empírico: regresión logística

La regresión logística obtuvo una exactitud promedio de $87,89 \% \pm 1,31 \%$ y un AUC (optimistic) de $0,758 \pm 0,051$. Para la clase 1, AI Studio informó una precisión promedio por partición de $25,69 \% \pm 3,64 \%$, un recall de $44,12 \% \pm 8,21 \%$ y un F1 de $32,28 \% \pm 4,44 \%$.

La matriz de confusión acumulada fue:

Cuadro 7: Matriz de confusión de la regresión logística.

	Predicha 0	Predicha 1
Verdadera 0	2196	218
Verdadera 1	95	75

A partir de estos conteos, la precisión agregada de la clase 1 es 25,60 %, el recall agregado es 44,12 % y el F1 agregado es 32,40 %. Las pequeñas diferencias entre la precisión y el F1 agregados y sus respectivos promedios por partición se deben a que AI Studio promedia los resultados de los pliegues, mientras que las métricas agregadas se calculan una sola vez sobre los conteos acumulados. El modelo identificó 75 de los 170 registros peligrosos y dejó 95 falsos negativos.

13. Experimento complementario con SMOTE

13.1. Metodología y flujos experimentales

Se documentan cuatro variantes verificadas con SMOTE: árbol de decisión, k-NN con $k = 5$, regresión logística y Naive Bayes. En todos los casos, SMOTE se aplica únicamente en *Training*, antes del learner, dentro de cada partición de la validación cruzada. *Testing* conserva la distribución original de las clases y recibe el modelo entrenado sin generar

ejemplos sintéticos. Este orden evita incorporar información de prueba en el entrenamiento y permite evaluar cada variante sobre una distribución comparable con la línea de base.

Para el árbol de decisión, el flujo utiliza SMOTE antes de *Decision Tree* y no incluye *Normalize*, dado que el learner no requiere una escala común para calcular distancias. En k-NN, se conserva *Normalize* antes de SMOTE y el modelo compuesto mantiene el preprocesamiento asociado al clasificador. Para la regresión logística, SMOTE precede a *Generalized Linear Model*. En Naive Bayes, el flujo conecta la salida sobremuestreada con el learner, aplica el modelo al conjunto de testing y calcula el desempeño mediante *Performance*. Las Figuras 10, 11, 12 y 13 muestran los cuatro flujos implementados.




Figura 10: Flujo de árbol de decisión con SMOTE aplicado únicamente en *Training*, sin incorporar *Normalize*.




Figura 11: Flujo de k-NN con $k = 5$, conservando *Normalize* antes de SMOTE y aplicando el modelo sobre *Testing* sin sobremuestreo.




Figura 12: Flujo de regresión logística con SMOTE aplicado únicamente en *Training*, antes de *Generalized Linear Model*.




Figura 13: Flujo de Naive Bayes con SMOTE aplicado en *Training*, seguido de *Apply Model* y *Performance*.

13.2. Resultados comparativos

La Tabla 8 resume los valores micro o agregados disponibles para las cuatro variantes, junto con la variabilidad informada por AI Studio cuando fue proporcionada. La cuádrupla final de cada fila expresa $TN / FP / FN / TP$. La tabla se mantiene separada de la comparación principal de los cuatro modelos base, porque SMOTE modifica el procedimiento de entrenamiento.

Cuadro 8: Comparación de las cuatro variantes verificadas con SMOTE.

Variante	Exactitud	AUC (optimistic)	Precisión clase 1	Recall clase 1	F1 clase 1	TN / FP / FN / TP
Árbol de decisión	80,77 % $\pm$ 4,33 %	0,812 $\pm$ 0,065	18,62 % $\pm$ 3,74 %	57,06 % $\pm$ 10,89 %	28,08 % $\pm$ 5,21 %	1990 / 424 / 73 / 97
k-NN ($k = 5$)	79,68 %	0,753	14,71 %	43,53 %	21,99 %	1985 / 429 / 96 / 74
Regresión logística	51,63 %	0,757	10,24 %	81,76 %	18,19 %	1195 / 1219 / 31 / 139
Naive Bayes	69,93 % $\pm$ 17,58 %	0,748 $\pm$ 0,034	13,65 % $\pm$ 3,58 %	67,06 % $\pm$ 11,55 %	22,69 % $\pm$ 5,08 %	1693 / 721 / 56 / 114

En el árbol de decisión, el encabezado de AI Studio informa una exactitud de 80,76 %; la tabla conserva 80,77 % como valor micro o agregado de la captura y añade la variabilidad disponible. En Naive Bayes, la captura de AI Studio informa una exactitud de 69,94 % y un promedio micro de 69,93 %; se incorpora en la tabla el valor micro de 69,93 %, junto con

la variabilidad mostrada. La matriz de esta variante contiene 1693 verdaderos negativos, 721 falsos positivos, 56 falsos negativos y 114 verdaderos positivos.

Frente a sus respectivas líneas de base, las cuatro variantes con SMOTE aumentan el recall y reducen los falsos negativos: el árbol pasa de 2,94 % a 57,06 % de recall y de 165 a 73 falsos negativos; k-NN pasa de 9,41 % a 43,53 % y de 154 a 96; la regresión logística pasa de 44,12 % a 81,76 % y de 95 a 31; y Naive Bayes pasa de 41,18 % a 67,06 % y de 100 a 56. En todos los casos, esta mejora en la detección se obtiene a costa de un aumento de falsos positivos y de una precisión de la clase 1 baja. En Naive Bayes, los falsos positivos ascienden a 721 y la precisión queda en 13,65 %, por lo que el aumento del recall no equivale a una mejora global.

En consecuencia, SMOTE no demuestra una superioridad global frente a las bases. La regresión logística con SMOTE alcanza el mayor recall y la menor cantidad de falsos negativos, pero también concentra la mayor cantidad de falsos positivos. Naive Bayes con SMOTE ocupa una posición intermedia en detección: recupera 114 de los 170 casos peligrosos, pero clasifica como positivos 835 registros, de los cuales 721 son falsos positivos. Por lo tanto, SMOTE mejora la cobertura de la clase 1, pero su conveniencia depende de cuánto se penalicen las falsas alarmas.

14. Comparación final de los cuatro modelos base

La Tabla 9 compara los cuatro algoritmos ejecutados. Para la precisión, el recall y el F1 de la clase 1 se utilizan valores agregados calculados a partir de las matrices de confusión totales. La exactitud y el AUC (optimistic) corresponden a los valores reportados por AI Studio; cuando la herramienta informó variabilidad entre particiones, se conserva el término $\pm$. Por tanto, no deben confundirse los promedios por pliegue con los cocientes derivados de los conteos acumulados.

Cuadro 9: Comparación final de los cuatro modelos base.

Modelo	Exactitud	AUC (optimistic)	Precisión agregada clase 1	Recall agregado clase 1	F1 agregado clase 1
Árbol de decisión	92,84 % $\pm$ 0,27 %	0,860 $\pm$ 0,041	20,00 %	2,94 %	5,13 %
Naive Bayes	84,75 % $\pm$ 4,31 %	0,761 $\pm$ 0,043	19,23 %	41,18 %	26,22 %
k-NN ($k = 5$)	93,07 %	0,851	39,02 %	9,41 %	15,17 %
Regresión logística	87,89 % $\pm$ 1,31 %	0,758 $\pm$ 0,051	25,60 %	44,12 %	32,40 %

La Figura 14 hace visible que ningún modelo domina simultáneamente las tres métricas de la clase peligrosa. k-NN presenta la mayor precisión agregada, mientras que la regresión logística alcanza el mayor recall y F1. El árbol de decisión mantiene una cobertura muy baja de la clase 1 y Naive Bayes recupera una proporción considerable de positivos, aunque con menor precisión.

La matriz de cada modelo completa esta comparación: el árbol de decisión produjo 20 falsos positivos y 165 falsos negativos; Naive Bayes, 294 y 100; k-NN, 25 y 154; y la regresión logística, 218 y 95, respectivamente. Frente al árbol de decisión y a k-NN, la regresión logística aumenta la detección de eventos peligrosos a costa de un mayor número de falsos positivos. En cambio, frente a Naive Bayes mejora simultáneamente los verdaderos positivos (75 frente a 70), los falsos negativos (95 frente a 100), los falsos positivos (218 frente a 294) y la exactitud (87,89 % frente a 84,75 %).




Figura 14: Comparación de la precisión, el recall y el F1 agregados de la clase 1 para los cuatro modelos base.

15. Discusión de los resultados empíricos

Los cuatro resultados empíricos permiten analizar el efecto del desbalance sobre la evaluación. El árbol de decisión base obtiene 92,84 % de exactitud, valor cercano a la proporción de la clase mayoritaria, pero su recall agregado de la clase 1 es 2,94 %. El resultado es consistente con un modelo que clasifica correctamente muchos registros no peligrosos y que, al mismo tiempo, deja sin detectar la mayor parte de los casos peligrosos.

Naive Bayes base presenta un comportamiento diferente. Su exactitud de 84,75 % es menor, pero su recall agregado alcanza 41,18 % y su F1 agregado 26,22 %, frente a 5,13 % del árbol. La mejora en detección se obtiene a costa de 294 falsos positivos. En un escenario donde una alarma adicional es aceptable frente a la omisión de un evento, este intercambio podría ser preferible; en un escenario donde las falsas alarmas generan interrupciones costosas, la decisión podría ser distinta.

El k-NN seleccionado con $k = 5$ alcanza una exactitud de 93,07 %, un AUC (optimistic) de 0,851, una precisión de clase 1 de 39,02 %, un recall de 9,41 % y un F1 de 15,17 %. En comparación con el árbol base, identifica más casos peligrosos, aunque todavía deja 154 falsos negativos. Estos resultados muestran que la normalización y la selección de k permiten configurar el modelo de manera reproducible, pero no eliminan por sí solas la dificultad asociada al desbalance.

La regresión logística alcanza el mayor recall y el mayor F1 agregados de los cuatro modelos base: 44,12 % y 32,40 %, respectivamente. Esta mejora implica detectar 75 casos peligrosos, frente a 70 de Naive Bayes, 16 de k-NN y 5 del árbol. Frente al árbol de decisión y a k-NN, la mayor cobertura se obtiene a costa de más falsos positivos y de una exactitud inferior. Frente a Naive Bayes, en cambio, la regresión logística mejora simultáneamente los verdaderos positivos (75 frente a 70), los falsos negativos (95 frente a 100), los falsos positivos (218 frente a 294) y la exactitud (87,89 % frente a 84,75 %). Por lo tanto, el costo en falsas alarmas no aumenta respecto de todos los modelos, sino únicamente respecto de

las alternativas más conservadoras en la predicción de la clase peligrosa.

Naive Bayes con SMOTE confirma el efecto esperado del sobremuestreo: frente a Naive Bayes base, el recall aumenta de 41,18 % a 67,06 % y los falsos negativos disminuyen de 100 a 56. Sin embargo, los falsos positivos aumentan de 294 a 721 y la precisión disminuye de 19,23 % a 13,65 %. El AUC (optimistic) de 0,748 indica una capacidad de discriminación moderada dentro del criterio configurado en AI Studio, pero no define por sí mismo un umbral operativo.

El AUC (optimistic) debe leerse con cautela. Los procesos RMP disponibles activan este criterio en *Performance* y desactivan el AUC estándar; por ello, la denominación se conserva de forma consistente. Estos valores no fueron recalculados a partir de predicciones exportadas, de modo que su comparación se limita al criterio homónimo reportado por AI Studio.

Por estas razones, la regresión logística base constituye la referencia más equilibrada entre los modelos base, porque obtiene el mayor F1 de la clase 1 (32,40 %). Si la prioridad exclusiva fuera minimizar falsos negativos, la regresión logística con SMOTE sería la alternativa más eficaz, con 81,76 % de recall, aunque produciría 1219 falsos positivos. Naive Bayes con SMOTE mejora la detección respecto de su versión base, pero su F1 de 22,69 % y su precisión de 13,65 % no lo convierten en la configuración principal. La conclusión final es que SMOTE es útil para aumentar la cobertura de eventos peligrosos, pero no reemplaza la selección del umbral ni la definición de costos antes de cualquier uso operativo.

16. Conclusiones

El análisis comparativo muestra que la exactitud global no es suficiente para evaluar la clasificación de eventos sísmicos peligrosos debido al fuerte desbalance entre las clases. El árbol de decisión y k-NN alcanzan exactitudes elevadas, pero detectan una proporción reducida de la clase 1. La regresión logística base presenta el mejor F1 agregado entre los modelos base, mientras que la regresión logística con SMOTE alcanza el mayor recall de todas las variantes evaluadas.

El experimento Naive Bayes + SMOTE queda incorporado como resultado final del proyecto. Su exactitud fue de 69,93 %, su AUC (optimistic) de 0,748, su precisión de la clase 1 de 13,65 %, su recall de 67,06 % y su F1 de 22,69 %. La matriz de confusión registró 1693 verdaderos negativos, 721 falsos positivos, 56 falsos negativos y 114 verdaderos positivos. Estos valores muestran una mejora clara en detección respecto de Naive Bayes base, acompañada por un aumento importante de falsas alarmas.

En síntesis, el proyecto responde la pregunta de investigación dentro del alcance definido: los modelos presentan comportamientos diferentes y el tratamiento del desbalance modifica sustancialmente el equilibrio entre detección y falsas alarmas. La regresión logística base queda como referencia equilibrada por F1; la regresión logística con SMOTE queda como alternativa de máxima cobertura. Ningún resultado debe interpretarse como autorización para operar un sistema de alertas sin una validación temporal, un análisis de costos y una selección explícita del umbral de decisión.

17. Referencias

- Sikora, M., y Wrobel, L. (2010). *Seismic-Bumps*. UCI Machine Learning Repository. <https://archive.ics.uci.edu/dataset/266/seismic+bumps>
- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). *SMOTE: Synthetic Minority Over-sampling Technique*. Journal of Artificial Intelligence Research, 16, 321–357. URL: <https://doi.org/10.1613/jair.953>